



Campus Estado de México

Inteligencia Artificial Avanzada para la Ciencia de Datos

Módulo 2: Aprendizaje máquina

Reporte Árbol de Decisión ID3 sin framework

Juan Pablo Solís Gómez A01800430

Prof: Jorge Adolfo Ramírez Uresti

1. Dataset de entrenamiento y prueba

Se utilizó el dataset coches_deportivos.csv, con 200 ejemplos y 7 atributos categóricos: Motor, Traccion, Peso, Potencia, Transmision, Aerodinamica y Marca. La variable objetivo es Performance, con dos clases posibles: Alta y Baja.

El dataset se dividió aleatoriamente en 80% para entrenamiento y 20% para prueba, usando una semilla fija (random.seed(42)) para que la partición sea reproducible:

Conjunto	Número de ejemplos
Entrenamiento	160
Prueba	40

2. Matriz de confusión y métricas

El árbol se entrenó con el 80% de los datos y se evaluó prediciendo la clase de cada uno de los 40 ejemplos de prueba, comparando la predicción contra el valor real de Performance. La matriz de confusión resultante fue:

	Real: Alta	Predicho: Baja
Real: Alta	21	7
Real: Baja	3	9

A partir de la matriz se calcularon las siguientes métricas:

Métrica	Fórmula	Valor
Accuracy	$(VP+VN) / \text{Total}$	0.75 (75.0%)
Precision	$VP / (VP+FP)$	0.875 (87.5%)
Recall	$VP / (VP+FN)$	0.75 (75.0%)
F1	$2 \cdot (\text{Prec} \cdot \text{Rec}) / (\text{Prec} + \text{Rec})$	0.8077

VP = verdaderos positivos, FP = falsos positivos, VN = verdaderos negativos, FN = falsos negativos

3. Verificación de que el algoritmo funciona

En el set de entrenamiento completo (160 ejemplos) hay 106 casos de clase Alta y 54 de clase Baja. Calculando $H(S)$ a mano con la formula:

$$p(\text{Alta}) = \frac{106}{160} = 0.6625 \quad p(\text{Baja}) = \frac{54}{160} = 0.3375$$

$$H(S) = -(0.6625 \cdot \log_2 0.6625 + 0.3375 \cdot \log_2 0.3375) = \mathbf{0.9224}$$

Este valor coincide exactamente con el que produce calcular_entropia(entrenamiento, "Performance") al correr el programa: 0.9224062617590723.

El árbol construido elige **Traccion** como atributo raíz. Verificando a mano: al dividir por Traccion se obtienen 3 subconjuntos:

Valor de Traccion	n	Alta	Baja	Entropía
Trasera	56	47	9	0.6360
Delantera	44	11	33	0.8113
Integral	60	48	12	0.7219

$$\text{Entropía ponderada} = \left(\frac{56}{160}\right) \cdot 0.6360 + \left(\frac{44}{160}\right) \cdot 0.8113 + \left(\frac{60}{160}\right) \cdot 0.7219 = 0.7164$$

$$\text{Ganancia(Traccion)} = 0.9224 - 0.7164 = \mathbf{0.2059762}$$

Este cálculo manual coincide con la salida real de calcular_ganancia: 0.20597627574132438.

Análisis y conclusión

El árbol clasifica correctamente 30 de los 40 vehículos de prueba (75% de exactitud), un desempeño notablemente mejor que una decisión trivial (por ejemplo, predecir siempre la clase mayoritaria del set de prueba, que habría dado 70% de exactitud, ya que 28 de 40 ejemplos son de clase Alta). La precisión (87.5%) es más alta que la exhaustividad (75%): cuando el modelo predice "Alta", acierta la gran mayoría de las veces (solo 3 falsos positivos), pero deja escapar 7 vehículos que en realidad eran de rendimiento Alta y fueron clasificados como Baja (falsos negativos). El F1-score de 0.81 refleja ese balance razonable entre ambos tipos de error, con una ligera inclinación hacia ser "conservador" al predecir la clase Alta.

Dos factores limitan qué tan generalizables son estas conclusiones: primero, el conjunto de prueba es pequeño (40 ejemplos), por lo que un pequeño cambio en la partición aleatoria podría mover las métricas de forma notoria. Segundo, ID3 sin poda construye ramas hasta que cada hoja es pura, lo que puede generar reglas muy específicas para combinaciones de atributos poco frecuentes en el entrenamiento y favorecer el sobreajuste (overfitting), una posible vía de mejora sería limitar su profundidad.

Al final, el árbol logra un desempeño consistentemente por encima de una línea base ingenua, con una precisión particularmente alta al identificar vehículos de rendimiento Alta, lo que valida la implementación manual del algoritmo ID3 (cálculo de entropía, ganancia de información y construcción recursiva del árbol) como funcionalmente correcta para este dataset.